## Data Mining HW2

### Anil Varma B

September 24, 2019

Use BostonHousing dataset to do the following.

1. Conduct a principal components analysis on the data and comment on the results. Select new variables that contain at least 98% of information and write done the new variables which are the linear combination of original variables.

Figure 0.1: Summary of principal component analysis.

```
> pca_house$1oadings
Loadings:
                                           Comp.1 Comp.2 Comp.3 Comp.4 Comp.5 Comp.6 Comp.7 Comp.8 Comp.9 Comp.10 Comp.11 Comp.12 Comp.13 Comp.14 Comp.15 0.272 0.930 0.157 0.151 0.106
                                                                                                           -0.632 0.763
INDUS
                                                                                                                                                                                                      -0.126 0.860
                                                                                                                                                                                                                                                                                                  -0.465
CHAS
NOX
                                                                                                                                                                                                                                                                                                                                                                                                                                              0.990 -0.137
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                 0.107
RM
                                                                                                                                                                                                                                                                                                                                                                                                        -0.992
 AGE
                                                                                                              0.752 0.641
DIS
                                                                                                                                                                                                         -0.110 0.112
0.231 -0.360 -0.399 -0.797 -0.134
TAX
PTRATIO
                                                0.949 -0.293
                                                                                                                                                                                                                                                                                                   -0.153 0.973 -0.123
                                             -0.291 -0.956
LSTAT
                                                                                                                                                                            0.460
                                                                                                                                                                                                      MEDV
CAT..MEDV
                                                                                                                                                                                                                                                                                                                                                                                                         -0.110 -0.135 -0.983
                                                                 Comp.1 Comp.2 Comp.3 Comp.4 Comp.5 Comp.6 Comp.7 Comp.8 Comp.9 Comp.10 Comp.11 Comp.12 Comp.13 Comp.14 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000
 ss loadings
Proportion Var
Cumulative Var
                                                                 Comp. 15
1.000
 ss loadings
Proportion Var
Cumulative Var
                                                                           0.067
```

Figure 0.2: Loadings on principal component analysis.

#### New variables with linear combinations

biplot(house\_normalise\_pca)

```
Component1 = (0.949*TAX)+(-0.291*B)

Component2 = (-2.93*TAX)+(-0.956*B)

Component3 = (-0.632*ZN)+(0.752*AGE)
```

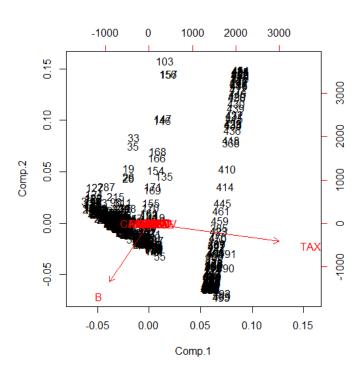


Figure 0.3: Bi plot of data.

#### 2. Should the data be normalized? Discuss what characterizes the components you consider

# key. Perform PCA on normalized data. Write down the new components and compare this result with a

Figure 0.4: Summary of principal component analysis.

Plotting a scree plot to choosing the 'optimal' number of principal components.

```
Rplot_scree_house_norm_pca
```

#### house\_normalise\_pca

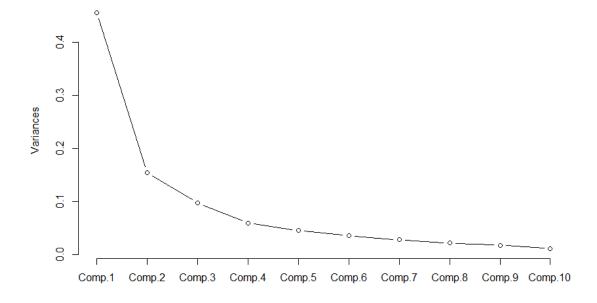


Figure 0.5: Scree plot of data.

```
> house_normalise_pca$loadings
Loadings:
           Comp.1 Comp.2 Comp.3 Comp.4 Comp.5 Comp.6 Comp.7 Comp.8 Comp.9 Comp.10 Comp.11 Comp.12 Comp.13 Comp.14 Comp.15 0.116 0.219 0.286 0.684 0.604 0.204 0.360 -0.109 0.355 -0.404 0.411 -0.235 -0.364 -0.211 0.331
INDUS
                                                                                                                               0.151
             0.311
                             -0.175
                                                      -0.145
                                                              -0.254
                                                                       -0.694 -0.124
                                                                                        0.291
                                                                                                  0.122
                                                                                                           -0.394
CHAS
NOX
                            -0.323
-0.240
                                                               0.130
-0.175
                     0 154
                                     -0.912
                                                       0 114
                                                                                                                     0.786
                                                                                                                              -0.245
RM
                     0.183
                                                               -0.114
                                                                               -0.361
                                                                                                           -0.329
             0.306
AGE
                     0.134
                            -0.482
                                      0.220
                                                               0.466
                                                                       0.302 -0.476
                                                                                        0.183
                                                                                                                     -0.149
                                                                                                           -0.546
-0.334
0.524
DIS
RAD
             -0.199
0.468
                     -0.134
0.315
                             0.286
                                     -0.114
-0.157
                                                                                                                    -0.222
-0.167
                                                                        0.396
                                             -0.141
                                                                                                  0.263
                                                      -0.211
                                                                                        0.227
                                                                                                                              -0.152
                                                                                                                                        0.177
TAX
             0.419
                     0.205
                             0.310
                                                                       -0.130
                                                                               -0.113
                                                                                                 -0.442
                                                                                                                     0.151
PTRATIO
B
LSTAT
            0.192
-0.168
                                              -0.552
                                                      0.452
                                                                               -0.145
0.120
                     -0.160
                                                               0.369
                                                                      -0.351
                                                                                        -0.317
                                              -0.663
0.184
                                                               0.431
             0.218
                                                                                0.529
                                                                                        0.187
                                                                                                  0.161
                                                                                                           -0.159
                                                                                                                                        0.238
MEDV
            -0 207
                     0 303
                                                               -0 259
                                                                                -0 220
                                                                                        0.128
                                                                                                                    -0.357
                                                                                                                              -0 383
CAT. MEDV
                                      0.214
                                                       0.111
                                                               0.228
                                                                       -0.217
                                                                                                 -0.176
                                                                                                                               0.122
                 SS loadings
Proportion Var
                                                             0.400
Cumulative Var
                   0.067
                           0.133
                                   0.200
                                            0.267
                                                    0.333
                                                                     0.467
                                                                             0.533
                                                                                      0.600
                                                                                                0.667
                                                                                                         0.733
                                                                                                                            0.867
                                                                                                                                      0.933
                 Comp. 15
1.000
0.067
SS loadings
Proportion Var
Cumulative Var
```

Figure 0.6: Loadings on principal component analysis.

#### New variables with linear combinations

```
 \begin{tabular}{ll} Component 1 &= (-0.204*ZN) + (-0.311*INDUS) + (0.283*NOX) + (0.306*AGE) + (-0.199*DIS) + (0.468*RAD) + (0.419*TAX) + (0.192*PTRATIO) + (-0.168*B) + (0.218*LSTAT) + (-0.207*MEDV) + (-0.285*CAT..MEDV) \\ and so on till the 13th variable for achieving 98 percent. \\ \end{tabular}
```

We plot a biplot to show in case of a normalised data set we have the principal components are orthogonal to each other and also capture maximum data.

biplot(house\_normalise\_pca)

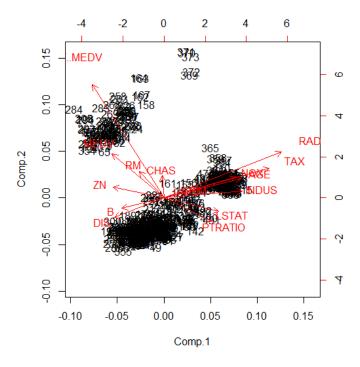


Figure 0.7: Bi plot of data.